# CIÊNCIA DE DADOS NAS APOSTAS DESPORTIVAS

*Fábio Alexandre Alves Gonçalves (130662); faags@iscte-iul.pt*
*Francisco do Carmo Gonçalves (130649); fdcgs@iscte-iul.pt*
*Joaquim Matias de Oliveira (130657); jmoas@iscte-iul.pt*
*Nuno Rodrigues Costa (130661); nrcas@iscte-iul.pt*

Licenciatura em Ciência de Dados
ISCTE-IUL
Av. Forças Armadas, 1649-026 Lisboa, Portugal

**RESUMO**

A crescente complexidade das apostas desportivas, particularmente no contexto das apostas ao vivo, tem impulsionado a adoção de modelos de ciência de dados por parte das casas de apostas.

Este artigo analisa como técnicas estatísticas e algoritmos de *machine learning* são utilizados na definição dinâmica de probabilidades (*odds*), com base em dados históricos, variáveis contextuais e comportamento dos apostadores. São abordados modelos como a regressão logística, a distribuição de Poisson, redes neurais e *transformers*, bem como metodologias de atualização em tempo real suportadas por infraestruturas computacionais avançadas. Discute-se ainda o impacto de eventos imprevistos, como decisões do VAR, e os desafios associados à ética, à qualidade dos dados e à regulamentação.

Conclui-se que, apesar de a ciência de dados aumentar a precisão e a eficiência neste setor, persistem limitações técnicas e legais que exigem uma monitorização contínua.

***Palavras-chave*** — ciência de dados; apostas desportivas; probabilidades (*odds*); *machine learning*; modelos de previsão

## 1. INTRODUÇÃO

Nas últimas décadas, o mercado das apostas desportivas online registou um crescimento exponencial, impulsionado pelo acesso generalizado a plataformas digitais e pela utilização massiva de dispositivos móveis. Neste contexto altamente competitivo e dinâmico, a definição de probabilidades (*odds*), que representam a probabilidade implícita de ocorrência de determinados eventos, tornou-se uma tarefa central para as casas de apostas, com impacto direto na sua sustentabilidade económica e na atração de apostadores.

Tradicionalmente, a definição de probabilidades baseava-se em modelos estatísticos clássicos e na experiência de especialistas. No entanto, a crescente complexidade dos eventos desportivos, aliada à emergência das apostas ao vivo (*live betting*), tornou estas abordagens insuficientes. A necessidade de atualizar probabilidades em tempo real, em resposta a eventos como golos, lesões ou decisões do VAR, exige soluções tecnológicas de elevada capacidade computacional.

Neste novo paradigma, a ciência de dados assume um papel central. Através da utilização de modelos preditivos baseados em dados históricos e contextuais, bem como de algoritmos de *machine learning*, é possível estimar probabilidades com maior precisão e adaptá-las continuamente às condições do jogo e ao comportamento do mercado. Assim, o presente artigo propõe-se analisar estas metodologias, discutir os principais desafios enfrentados pelas operadoras e refletir sobre as implicações éticas e legais associadas à automatização das probabilidades.

## 2. FUNDAMENTOS DAS APOSTAS DESPORTIVAS

### 2.1. Probabilidades (*odds*) e Apostas ao Vivo

No contexto das apostas desportivas, o termo probabilidades (*odds*) designa a expressão numérica da probabilidade implícita de ocorrência de um evento, traduzida em termos de retorno financeiro por unidade apostada. Embora próximas do conceito de probabilidade, as *odds* representam uma forma ajustada de quantificar a incerteza, sendo estruturadas como um rácio entre o potencial ganho e o montante investido. Esta métrica é essencial para o equilíbrio económico dos mercados de apostas, permitindo a gestão simultânea do risco e da rentabilidade.

As probabilidades apresentam uma relação inversa com a probabilidade implícita: quanto maior a *odd*, menor a probabilidade associada ao evento. A sua notação varia conforme a região: as *odds* decimais (predominantes na Europa) representam diretamente o multiplicador do retorno; as fracionárias (utilizadas no Reino Unido) expressam a razão entre lucro e valor apostado; e as americanas distinguem ganhos potenciais com base no montante necessário para obter um lucro fixo ou no lucro obtido a partir de um determinado investimento.

Adicionalmente, as apostas combinadas resultam da agregação de múltiplos eventos, aumentando o retorno potencial, mas também o risco associado. Neste contexto, a definição das probabilidades baseia-se na análise de dados históricos, variáveis contextuais e comportamento do mercado, exigindo modelos quantitativos sofisticados.

As probabilidades não constituem apenas um reflexo direto de probabilidades objetivas, sendo também influenciadas por fatores comerciais e estratégicos das casas de apostas. Assim, não visam apenas representar a realidade de forma neutra, mas também influenciar a perceção de risco e o comportamento dos utilizadores. A sua construção recorre a técnicas de *psychological pricing*, em que pequenas variações nos valores podem ser estrategicamente utilizadas para influenciar decisões, um fenómeno estudado na interseção entre a economia comportamental (*Behavioral Economics*) e a ciência de dados.

## 2.2. Modelos Preditivos e Cálculo de *Odds* em Futebol

As casas de apostas desportivas recorrem a modelos preditivos baseados em ciência de dados para definir as probabilidades (*odds*) associadas a eventos de futebol. A determinação precisa dessas probabilidades é fundamental para garantir cotações consistentes com a realidade do jogo, ao mesmo tempo que incorporam margens de lucro que asseguram a sustentabilidade do negócio.

Para estimar a probabilidade de cada resultado possível, são utilizados diferentes modelos estatísticos e de aprendizagem automática, especialmente em cenários binários como vitória ou derrota. De seguida, apresentam-se os principais modelos e o seu funcionamento.

**Regressão Logística:** A regressão logística é amplamente utilizada para prever resultados binários, como a vitória de uma equipa. Este modelo recorre a variáveis explicativas, como a forma recente, a força relativa das equipas, o histórico de confrontos ou a vantagem de jogar em casa, para estimar a probabilidade de ocorrência de um determinado evento. O resultado é uma probabilidade compreendida entre 0 e 1, permitindo uma interpretação direta do risco associado.

Uma função sigmoide modela a probabilidade de vitória da equipa da casa em função da diferença média de golos: 0 corresponde a cerca de 50%, valores positivos aumentam-na e negativos reduzem-na.

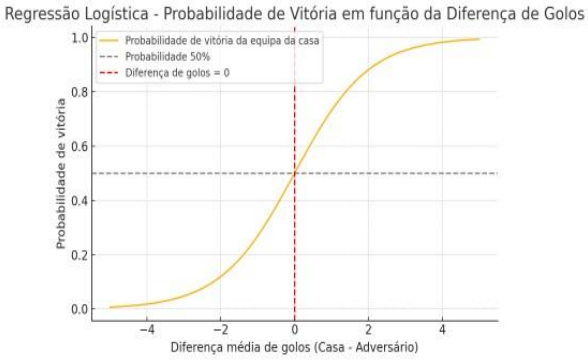


**Figura I. Gráfico de Regressão Logística**

**Modelo de Poisson:** O modelo de Poisson é particularmente adequado para desportos de baixo número de golos, como o futebol, permitindo estimar a distribuição do número de golos esperados para cada equipa. Com base na força ofensiva e defensiva e na vantagem de jogar em casa, calcula-se o valor esperado de golos ($\lambda$), a partir do qual se obtêm as probabilidades de marcar um determinado número de golos.

A partir destas distribuições, é possível construir tabelas de probabilidades para diferentes combinações de resultados (placares). A probabilidade de vitória de uma equipa corresponde à soma das probabilidades dos cenários em que marca mais golos do que o adversário.

*Exemplo:* Uma matriz de probabilidades pode representar os possíveis resultados entre duas equipas, onde diferentes cores identificam vitórias da equipa da casa, do visitante e empates. A soma dessas probabilidades permite obter a distribuição final dos resultados.

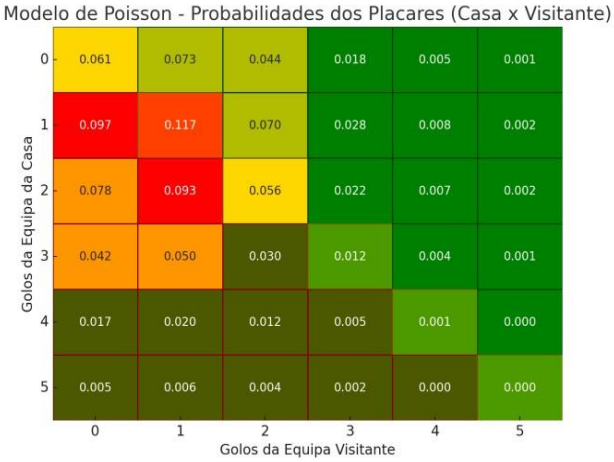


**Figura II. Modelo de Poisson**

**Modelos de Machine Learning:** Algoritmos de *machine learning*, como *random forests* e *gradient boosting* (por exemplo, XGBoost), são amplamente utilizados para prever resultados desportivos. Estes modelos capturam relações complexas entre variáveis, como estatísticas de jogo, rankings, posse de bola e métricas avançadas de desempenho, superando frequentemente modelos lineares tradicionais.

Ao contrário dos modelos estatísticos clássicos, os algoritmos de *machine learning* adaptam-se a grandes volumes de dados e conseguem identificar padrões não lineares. Modelos mais avançados, como redes neurais, são utilizados para analisar séries temporais ou dados de rastreamento de jogadores. No entanto, apresentam geralmente menor interpretabilidade.

Para alcançar previsões mais precisas, os modelos são treinados com grandes volumes de dados históricos, incluindo variáveis como golos marcados, remates enquadrados, posse de bola, forma recente, histórico de confrontos e condições externas. Estudos demonstram que variáveis contextuais, como o local do jogo e o momento de forma das equipas, têm um impacto significativo na precisão dos modelos.

Durante o treino, os algoritmos ajustam os seus parâmetros internos para minimizar o erro entre previsões e resultados observados. Por exemplo, na regressão logística, são atribuídos pesos às variáveis de modo a calibrar as probabilidades de vitória.

Por fim, técnicas como validação cruzada e otimização de hiperparâmetros são utilizadas para evitar o sobreajuste (*overfitting*) e garantir a robustez dos modelos em dados futuros. Desta forma, obtêm-se sistemas capazes de estimar probabilidades de forma consistente e adaptável a diferentes contextos competitivos.

### 2.3. Ajuste Dinâmico das *Odds* e Gestão de Risco

A probabilidade estimada inicialmente por um modelo não corresponde necessariamente àquela que é oferecida até ao momento do jogo, uma vez que as *odds* são ajustadas dinamicamente à medida que o mercado de apostas evolui. À medida que a partida se aproxima e os apostadores distribuem o seu dinheiro por diferentes opções, a casa de apostas monitoriza o volume de apostas em cada resultado, ajustando as probabilidades de forma a equilibrar o risco.

Para além do fluxo financeiro, novas informações externas podem conduzir a alterações nas probabilidades e, consequentemente, nas *odds*. Por exemplo, a lesão de um jogador-chave da equipa favorita na véspera do jogo, ou condições meteorológicas adversas no dia da partida, podem alterar significativamente as probabilidades reais dos diferentes desfechos.

Nestes casos, as casas de apostas recalibram as *odds* quase em tempo real para incorporar essa nova informação, aumentando a *odd* associada à equipa afetada e ajustando as restantes probabilidades em conformidade. Em jogos de elevada relevância, é comum observar oscilações frequentes nas *odds* antes do início da partida, refletindo a incorporação contínua de informação, rumores e o volume de apostas em cada resultado.

## 3. AJUSTE DE PROBABILIDADES (*ODDS*) EM TEMPO REAL

### 3.1 Apostas ao Vivo e a Necessidade de Atualização Constante

As apostas ao vivo (*in-play betting*) permitem que os apostadores realizem previsões durante o decorrer de um evento desportivo. Este tipo de apostas exige que as probabilidades (*odds*) sejam constantemente atualizadas, de forma a refletir alterações no jogo, como golos, expulsões ou lesões. O funcionamento eficiente destes mercados depende da transmissão, ingestão e processamento de dados com latência mínima. Qualquer atraso entre um acontecimento no campo e a respetiva atualização das probabilidades pode ser explorado por apostadores com acesso a transmissões mais rápidas, criando desequilíbrios no mercado.

A latência resulta de várias etapas do fluxo de dados: desde a captação de eventos no estádio (através de sensores, câmaras ou observadores), passando pela transmissão para fornecedores de dados (*data feeds*), até ao processamento pelas casas de apostas. Segundo Michels et al. (2022), o atraso médio entre um evento e a sua tradução nas probabilidades pode variar entre 1 e 5 segundos, dependendo da infraestrutura utilizada e da distância geográfica entre sistemas.

Adicionalmente, existem desafios operacionais relevantes. O recurso ao VAR, por exemplo, introduz interrupções que obrigam à suspensão temporária dos mercados (*trading freeze*), exigindo uma sincronização rigorosa entre os dados recebidos e os modelos de previsão. Durante estes períodos, qualquer falha pode resultar em prejuízos para a casa de apostas ou em oportunidades exploráveis por utilizadores mais informados (Ötting et al., 2021).

Durante uma revisão de VAR, especialmente em situações críticas como golos, penáltis ou cartões vermelhos, os mercados são temporariamente suspensos. Esta medida é essencial para evitar a colocação de apostas com base em informação desatualizada, uma vez que pode existir uma diferença temporal entre a transmissão visual e a atualização dos sistemas. Como referem Ötting et al. (2021), estas pausas mitigam assimetrias de informação que, de outro modo, poderiam ser exploradas.

Após a decisão do VAR, os sistemas reagem de forma imediata, recalculando as probabilidades com base no novo estado do jogo e reabrindo os mercados. Estudos indicam que, durante estes períodos, a atividade dos apostadores tende a diminuir, enquanto as probabilidades se tornam mais voláteis após a reabertura, até que os modelos assimilem completamente a nova informação (Michels et al., 2022).

Atualmente, as casas de apostas recorrem a técnicas de inteligência artificial para prever eventos de curto prazo durante os jogos. Para tal, analisam em tempo real variáveis como posse de bola, número de remates, faltas e outros indicadores de desempenho. Com base nesses dados, é possível estimar a probabilidade de eventos como golos, cartões ou cantos.

Uma das abordagens utilizadas baseia-se em redes neurais recorrentes, nomeadamente modelos do tipo LSTM (*Long Short-Term Memory*), que são eficazes na identificação de padrões temporais. Estes modelos conseguem captar a evolução do jogo ao longo do tempo e antecipar acontecimentos futuros. Por exemplo, uma sequência contínua de ataques pode indicar uma maior probabilidade de golo iminente. Estudos como o de Nghiem et al. (2022) demonstram a eficácia destes modelos na previsão de resultados desportivos.

Outra abordagem recente utiliza modelos baseados em mecanismos de atenção (*transformers*), originalmente desenvolvidos para o processamento de linguagem natural. Estes modelos permitem analisar sequências de dados e atribuir maior relevância aos momentos mais críticos do jogo, como períodos de pressão ofensiva. A sua capacidade de focar informação relevante torna-os particularmente eficazes na previsão de eventos em tempo real, como demonstrado por Shan et al. (2023).

## 4. DESAFIOS E LIMITAÇÕES

A utilização de modelos de inteligência artificial para calcular probabilidades (*odds*) em apostas desportivas apresenta vantagens significativas em termos de rapidez e precisão. No entanto, enfrenta desafios relevantes que afetam diretamente a sua fiabilidade e integridade, nomeadamente a qualidade dos dados, os eventos imprevistos, as questões éticas e as exigências legais.

O primeiro desafio prende-se com a qualidade e a quantidade dos dados. Os modelos baseiam-se em estatísticas históricas relativas a equipas, jogadores e resultados, entre outros fatores. Contudo, dados incompletos, desatualizados ou mal estruturados podem conduzir a probabilidades tendenciosas ou incorretas. Este problema é particularmente evidente em ligas menos mediáticas ou em situações com informação limitada. Além disso, quando os dados não refletem adequadamente a realidade atual — por exemplo, no caso de equipas afetadas por lesões — as probabilidades deixam de representar o verdadeiro risco. Assim, sem dados fiáveis, as *odds* tornam-se apenas uma ilusão de precisão.

O segundo desafio relaciona-se com a ocorrência de eventos imprevistos e mudanças de contexto. O desporto é intrinsecamente dinâmico e influenciado por fatores difíceis de antecipar, como lesões de última hora, alterações táticas, condições meteorológicas ou fatores psicológicos. Modelos baseados exclusivamente em dados históricos têm dificuldade em captar estas variações, podendo gerar probabilidades rapidamente desajustadas. Torna-se, por isso, essencial a integração de dados contextuais e a atualização contínua dos modelos, embora tal represente ainda uma limitação técnica relevante.

O terceiro aspeto crítico diz respeito às questões éticas. A utilização de algoritmos na definição de probabilidades levanta preocupações quanto à transparência e à equidade. Existe o risco de os modelos incorporarem enviesamentos, por exemplo, favorecendo equipas com maior visibilidade mediática ou explorando padrões comportamentais de utilizadores mais vulneráveis. Adicionalmente, a opacidade destes sistemas pode criar assimetrias de informação entre operadores e apostadores. Neste contexto, torna-se fundamental garantir que as probabilidades sejam geradas com base em critérios objetivos, transparentes e justos, permitindo decisões informadas por parte dos utilizadores.

Por fim, surgem os desafios legais. A definição automatizada de probabilidades envolve a utilização intensiva de dados, incluindo, em alguns casos, informação relativa ao comportamento dos utilizadores. Regulamentos como o RGPD impõem requisitos rigorosos em matéria de proteção de dados, nomeadamente ao nível do consentimento, da segurança e da transparência. Acresce ainda a questão da responsabilidade: em caso de erros ou decisões incorretas, não é sempre claro se a responsabilidade recai sobre a casa de apostas, o fornecedor tecnológico ou os desenvolvedores dos modelos. Esta incerteza evidencia a necessidade de maior regulação, auditorias independentes e mecanismos de supervisão eficazes.

Em síntese, a aplicação de inteligência artificial na definição de probabilidades tem o potencial de aumentar o rigor e a eficiência do setor das apostas desportivas. No entanto, a sua utilização sustentável depende da capacidade de enfrentar os desafios associados à qualidade dos dados, à imprevisibilidade do contexto, às questões éticas e à conformidade legal. Ignorar estes fatores compromete não só precisão das probabilidades, mas também a confiança dos utilizadores e a integridade do mercado.

## AGRADECIMENTOS

Os autores agradecem aos docentes da unidade curricular de Amostragem e Fontes de Informação do ISCTE-IUL pelo enquadramento teórico e pela orientação metodológica, fundamentais para a elaboração deste artigo.

Este trabalho foi igualmente enriquecido pela análise de literatura científica recente, nomeadamente os estudos de Galekwa et al. (2024), Michels et al. (2022), Nghiem et al. (2022), Ötting et al. (2021) e Shan et al. (2023), cujas contribuições se revelaram essenciais para a compreensão do papel da inteligência artificial e dos modelos preditivos na definição dinâmica de probabilidades (*odds*) no contexto das apostas desportivas.

## REFERÊNCIAS

[1] Galekwa, R. M., Tshimula, J. M., Tajeuna, E. G., & Kyamakya, K. (2024). *A systematic review of machine learning in sports betting: Techniques, challenges, and future directions*. [Em linha]. Disponível em: https://arxiv.org/abs/2410.21484 [Consult. 8 maio 2025].

[2] Michels, R., Ötting, M., & Langrock, R. (2022). *Bettors' reaction to match dynamics – Evidence from in-game betting*. [Em linha]. Disponível em: https://arxiv.org/abs/2202.10085 [Consult. 8 maio 2025].

[3] Nghiem, Q. H., Nguyen, H. H., & Nguyen, T. H. (2022). *Deep learning in sports outcome prediction: A case study with LSTM networks*. [Em linha]. Disponível em: https://arxiv.org/abs/2201.00001 [Consult. 10 maio 2025].

[4] Ötting, M., Michels, R., Langrock, R., & Deutscher, C. (2021). *The reaction to news in live betting*. [Em linha]. Disponível em: https://arxiv.org/abs/2108.00821 [Consult. 10 maio 2025].

[5] Shan, C., Xu, Y., Liu, J., Zhang, X., & Wang, H. (2023). *Transformer-based architectures for real-time sports analytics*. [Em linha]. Disponível em: https://arxiv.org/abs/2303.06021 [Consult. 10 maio 2025].

[6] Maria. (2024). *Como calcular probabilidades em apostas desportivas*. [Em linha]. Disponível em: https://www.bwin.pt/blog/como-calcular-probabilidades-em-apostas-desportivas/ [Consult. 11 maio 2025].

[7] União Europeia. Regulamento (UE) 2016/679 do Parlamento Europeu e do Conselho, de 27 de abril de 2016. *Regulamento Geral sobre a Proteção de Dados (RGPD)*. Jornal Oficial da União Europeia, L119, p. 1–88, 4 maio 2016. [Em linha]. Disponível em: https://eur-lex.europa.eu/eli/reg/2016/679/oj [Consult. 19 maio 2025].